

LSTM 기반 고가·저가 예측 모델을 활용한 암호화폐 선물거래 시스템

¹ 최민석, ² 주해종, ^{3*} 최웅

Cryptocurrency Futures Trading System Utilizing an LSTM-based High and Low Price Prediction Model

¹Minseok Choi, ²Haejong Joo and ^{3*}Woong Choi

요약

최근 인공지능을 활용하여 뉴스 기사나 경제지표 등 다양한 부가지표를 바탕으로 암호화폐 가격을 예측하는 연구들이 발표되고 있다. 본 연구는 암호화폐의 가격 예측에서 목표 자산의 가격지표만을 활용하여 선물거래 시 수익률을 개선하는 시스템을 설계하였으며, 선물거래의 특성을 반영하여 단순한 종가 데이터 대신 고가 및 저가 데이터를 학습에 활용함으로써 선물거래 트레이딩에 있어서 실질적인 이점을 추구했다. 이를 위해 RNN의 장기 의존성 문제를 해결하고 복잡한 시계열 데이터를 처리할 수 있는 LSTM 네트워크를 사용하여 추세를 예측하였고, 제안된 시스템은 종가 기반 예측 모델과 비교했을 때, 피어슨 상관계수와 승률 측면에서 소폭의 하락을 보였으나, 수익률 측면에서는 상당한 개선을 이뤄냈다. 구체적으로, ETH에서 6.27%, XRP에서 32.71%, DOGE에서 45.96%의 수익률 증가를 기록하였으며, 이를 통해 암호화폐 선물 거래에서 실질적인 가격 추세 예측이 가능할 것으로 기대된다.

Abstract

Recent studies have utilized artificial intelligence to predict cryptocurrency prices based on various supplementary indicators such as news articles and economic indicators. This study, however, designs a system that enhances profitability in futures trading by using only price indicators of the target asset. By reflecting the characteristics of futures trading, the system utilizes high and low price data instead of simple closing price data for model training, aiming to achieve practical advantages in futures trading. To this end, an LSTM network, capable of addressing the long-term dependency issue of RNNs and processing complex time series data, was employed for trend prediction. Compared to closing price-based models, the proposed system showed a slight decrease in Pearson correlation coefficient and win rate; however, it demonstrated significant improvements in profitability. Specifically, the system recorded a 6.27% increase in profitability for ETH, 32.71% for XRP, and 45.96% for DOGE. These results suggest that the proposed system can effectively predict price trends in cryptocurrency futures trading.

Keywords: Cryptocurrency, LSTM, Artificial Intelligence, Data Analysis, Futures Trading

¹ 강남대학교 소프트웨어응용학부 학부생 (minseok011017@gmail.com)

² 강남대학교 인공지능융합공학부 교수 (hjoo@kangnam.ac.kr)

^{3*}Corresponding Author 강남대학교 컴퓨터공학부 부교수 (wchoi@kangnam.ac.kr)

Received: Mar. 29, 2025, Revised: May. 21, 2025, Accepted: May. 27, 2025

I. 서론

2009 년 비트코인(Bitcoin)의 등장 이후 암호화폐는 금융 시장에 새로운 패러다임을 제시하였다. 블록체인(Blockchain) 기술을 기반으로 한 암호화폐는 중앙 기관의 통제를 받지 않으며, 거래 과정에서 프라이버시와 자유를 보장한다. 이러한 특성은 암호화폐를 개인 금융 거래에서 보안성을 강화한 수단으로 자리 잡게 하였으며, 동시에 새로운 투자 수단으로서 주목받고 있다. 그러나 암호화폐 시장은 그 변동성이 매우 크고, 규제가 없을 경우 범죄에 악용될 가능성이 있다는 점에서 규제의 필요성이 제기되기도 한다[1]. 그럼에도 불구하고 암호화폐 시장은 전통적인 금융 시장과 달리 24 시간 연중무휴로 운영되며, 높은 변동성으로 인해 투자자들에게 수많은 투자 기회를 제공하며 잠재적으로 큰 수익을 기대할 수 있다. 이에 따라 금융 자산으로서 암호화폐에 대해 연구가 이뤄지며[2], 투자자들은 실시간으로 변화하는 시장 데이터를 분석하고 최적의 거래 전략을 수립하기 위해 인공지능(Artificial Intelligence, AI)을 점점 더 많이 활용하고 있다[3][4].

최근 인공지능 기술의 발달로 암호화폐 시장에서도 다양한 알고리즘이 적용되고 있으며, 특히 머신러닝(Machine Learning)과 딥러닝(Deep Learning) 기술을 기반으로 한 자동 거래 시스템(Automated Trading System)이 주목받고 있다[5]. 이러한 시스템은 대규모 거래 데이터를 실시간으로 분석하고, 시장의 트렌드를 예측하며, 인간의 감정적 개입을 최소화하여 효율적인 거래를 가능하게 한다. 인공지능 자동 거래 시스템은 특히 암호화폐의 변동성을 탐지하여 최적의 거래 시점을 찾아내는 데 유용하며, 이를 통해 수학적·통계적 모델과 알고리즘에 기반한 퀀트 트레이딩(Quantitative Trading)을 실행한다. 이는 일관된 전략을 유지하며, 철저히 데이터에 기반한 매매 신호를 포착함으로써 더 일관된 수익 창출을 가능하게 한다.

LSTM 모델은 순환 신경망(Recurrent Neural Network, RNN)의 일종으로, 시계열 데이터(Time Series Data) 예측에 강점을 가진다[6][7]. 특히, 한 연구에 따르면, LSTM 과 GRU 등 순환 신경망 기반 모델은 Transformer 계열 모델보다 실거래 환경에서 더 낮은 예측 오류와 일관된 성능을 보이는 것으로 확인되었다[8]. 이는 데이터셋 규모가 크지 않거나 암호화폐 시장처럼 피쳐 구성이 단순하고 노이즈 및 변동성이 극단적으로 큰 환경에서 LSTM 의 반복적 기억 구조가 보다 안정적이고 견고하게 작동하기 때문이라는 점이 강조된다.

따라서 본 연구에서는 TFT(Temporal Fusion Transformer)와 같은 Transformer 기반 최신 모델이 아닌, 암호화폐의 자체 데이터만을 활용하는 것에 있어서 피쳐 구성의 단순성, 데이터 규모, 시장의 높은 변동성과 노이즈 수준을 종합적으로 고려하여 복잡성을 최소화하면서도 안정성을 보장하는 LSTM 을 활용한다.

이러한 인공지능을 활용한 암호화폐 선물 거래 시스템은 기존의 인간 투자자가 직접 거래하는 방식과 차별화된다. 인간 투자자는 급변하는 시장 상황에서 감정적으로 대응할 가능성이 높으며, 이는 부정적인 거래로 이어질 수 있다. 반면, 인공지능 시스템은 사전에 설정된 규칙에 따라 거래를 자동으로 실행하며, 인간의 실수를 최소화하고 체계적으로 일관된 전략을 유지할 수 있다. 또한, 방대한 데이터를 신속하고 정확하게 분석할 수 있는 능력을 갖추고 있어, 투자 의사 결정에 중요한 통찰을 제공한다.

인공지능 기반 암호화폐 거래 시스템이 모든 상황에서 완벽한 성과를 보장하는 것은 아니다. 암호화폐 시장은 예측 불가능한 요소들이 많고, 기존의 금융 시장과는 다른 특성을 지니고 있어 인공지능 모델이 모든 상황에 대응하기는 어렵다. 그러나 본 연구는 고가와 저가 데이터를 활용한 LSTM 모델이 암호화폐 시장에서 선물거래의 특성을 더 잘 반영하여 기존의 종가 데이터 기반 모델보다 더 나은 예측 성능을 보여줄 수 있다는 가능성을 제시한다.

결론적으로, 인공지능을 활용한 암호화폐 선물거래 시스템은 인간 투자자의 감정적 요소를 배제하고 효율적이며 일관된 거래를 가능하게 한다. 또한, 본 연구는 암호화폐 시장의 변동성을 반영한 가격 데이터와 LSTM 모델을 결합하여 기존 거래 방식보다 더 높은 수익성을 기대할 수 있음을 보여준다.

II. 암호화폐 가격 예측

2.1 관련 연구

암호화폐 시장은 다른 자산에 비해 변동성이 매우 크며, 이를 예측하기 위한 정교한 모델의 개발이 필요하다. 기존 연구들은 주로 시계열 데이터를 기반으로 한 딥러닝 기법을 활용하여 이러한 문제에 접근해왔다. 예시로, LSTM, GRU(Gated Recurrent Unit), 그리고 양방향 LSTM(Bi-directional LSTM) 등을 활용한 접근이 있으며, 이러한 모델들은 시계열 데이터의 패턴을 분석하는 데 강점을 보인다[9][10]. 또한, 복잡한 패턴을 더 정확하게 포착하는 Transformer 모델을 활용하여 기술적 지표, 경제 지표 등 다양한 입력 소스의 추가적인 피처를 통합해 암호화폐 가격 예측에 다중 변수를 통합한 연구가 있다[11].

기존 연구들에서는 암호화폐 가격 예측에 있어서 단순히 기술적 지표에만 의존하지 않고 소셜 미디어 플랫폼에서의 텍스트 데이터를 통해 감성 분석(Sentiment Analysis)을 결합한 연구들과 같은, 외부 요인을 통합하려는 시도도 활발히 이루어져 왔다[12][13][14]. 이와 관련하여 진행된 연구로서 소셜 미디어 플랫폼인 트위터 감성 분석을 통해 가격 변동성을 예측한 연구가 있으며[15][16], 뉴스 감성 분석을 통해 가격 변동을 예측하기도 한다[17][18]. 이러한 연구들은 대중의 심리 및 의견이 암호화폐 가격 변동에 미치는 영향을 분석함으로써, 보다 정교한 예측을 가능하게 한다. 감성 분석을 통해 수집된 데이터는 기존의 기술적 분석 결과와 결합되어 예측 모델의 다차원적 성격을 강화하고 예측 정확도를 높일 수 있다[19]. 이러한 접근법은 특히 비정형 데이터(unstructured data)의 중요성을 강조하며, 암호화폐 시장의 높은 변동성에 대응할 수 있는 새로운 방법론을 제시한다.

하지만, Transformer 와 LSTM 을 금융 시계열 데이터에서 비교한 연구에서는, Transformer 계열 모델이 다양한 피처를 통합하는 등의 특정 조건에서는 강점을 보였지만, 결과의 변동성이 크고 노이즈 및 시장 변동성에 취약하다는 한계가 지적되었다. 반면, LSTM 은 반복적 기억 구조 덕분에 노이즈가 많은 시계열 데이터에서도 안정적이며 일관된 방향성 예측 성능을 보였으며, 실제 트레이딩 환경에서도 과적합 없이 견고하게 적용 가능한 모델로 평가되었다[8]. 이러한 결과는 지나치게 복잡한 Attention 기반 모델보다는 일정 수준의 단순성과 신뢰성을 갖춘 LSTM 모델이 금융 시계열 예측 및 실전 전략 수립에 더욱 효과적일 수 있음을 시사한다. 본 연구는 이러한 선행 연구의 결론을 바탕으로, 단순한 구성의 피쳐 데이터인 암호화폐 가격 데이터를 활용하여 LSTM 기반 예측 모델을 구축함으로써 선물 거래의 수익률을 개선하는 가능성을 제시한다.

2.2 암호화폐 선물거래의 특성과 적용

본 연구는 암호화폐 자체의 가격 데이터를 기반으로 선물 거래 시스템(Futures Trading System)을 개발하는 데 중점을 두고 있으며, 암호화폐 선물 거래는 미래의 특정 시점에 약정된 가격으로 암호화폐를 매매할 수 있는 금융 계약으로, 투자자는 롱(Long) 포지션을 통해 가격 상승에 베팅하거나 숏(Short) 포지션을 통해 가격 하락에 베팅할 수 있다. 이러한 선물거래의 특성에 착안하여 기존 연구들이 주로 예측에 활용하던 종가(Close) 데이터 대신 고가(High)와 저가(Low) 데이터를 활용하여 LSTM 모델을 기반으로 예측 정확성을 높이려 한다. 이때, 그림 1 과 같이 종가는 특정 기간의 마지막 시점에서의 가격을 의미하며, 고가는 특정 기간에서 가장 가격이 높았던 순간을, 저가는 가장 낮았던 순간을 뜻한다. 이러한 데이터들은 암호화폐의 변동성 예측에 다양한 정보를 제공하며, 선물거래는 암호화폐 시장의 현물 변동성에 영향을 주기도 한다[20][21]. 이러한 변동성을 적극적으로 활용하는 선물거래 시장에서는 예측 정확성에 따라 높은 수익을 거둘 수 있다.




Figure 1. Candlestick chart: (a) when the closing price is higher than the opening price, (b) when the closing price is lower than the opening price

그림 1. 캔들 차트: (a) 종가가 시가보다 높을 경우, (b) 종가가 시가보다 낮을 경우

일반적인 금융 시장과 달리 암호화폐 시장에서는 급격한 가격 변동이 빈번하게 발생하는데, 이는 단순 종가 데이터만으로는 충분히 반영하기 어려운 특징이다. 따라서 본 연구는 고가와 저가 데이터를 포함한 분석이 종가를 활용한 예측보다 더 나은 예측 결과를 도출할 수 있을 것이라는 가설을 세웠다. 또한, 이러한 예측 모델을 활용한 실제 거래 성과를 평가함으로써 모델의 실효성을 검증할 수 있다. 암호화폐 시장의 변동성을 반영한 새로운 연구들이 계속해서 등장함에 따라, 앞으로 암호화폐 가격 예측 분야는 더욱 발전할 것으로 기대된다.

III. 암호화폐 선물거래 시스템 제안

본 연구는 대규모 거래량과 다양한 암호화폐 페어를 제공하는 주요 거래소인 바이낸스를 데이터 소스로 선정하였다. 트레이딩뷰(TradingView) 사이트를 통해 바이낸스 거래소에서 시가총액이 크고 BTC를 추종하는 주요 알트코인인 ETH, XRP, DOGE의 일별 데이터를 추출하였으며, 2022년 2월 1일부터 2023년 12월 31일까지의 시가(Open), 고가, 저가, 종가 데이터를 수집하였다. 데이터의 완전성을 확보하기 위해 누락된 데이터나 오류를 확인하는 과정을 거쳤으며, 제안된 모델의 성능은 고가와 저가 데이터를 정확히 예측하는 능력과 선물 거래에서의 수익률에 미치는 영향을 통해 평가되었다.

3.1 암호화폐 데이터 전처리

시계열 데이터를 모델에 입력하기 위해 타임스탬프 길이를 14로 설정하여 데이터를 전처리하였다. 모든 데이터는 MinMaxScaler를 사용하여 스케일링 처리하였으며, 그림 2와 같이 전체 데이터의 60%는 훈련 세트, 20%는 검증 세트, 나머지 20%는 테스트 세트로 분할하였다. 개선된 모델의 정답 데이터는 암호화폐 가격이 상승한 날은 최고가, 하락한 날은 최저가를 기입한 시계열 데이터를 사용하여 미래 암호화폐의 저가와 고가를 예측함으로써 선물 거래에서의 수익률 극대화를 목표로 설정하였다.

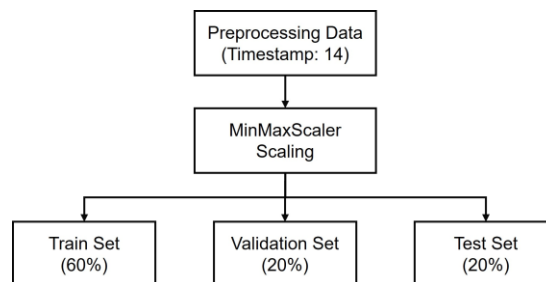


Figure 2. Data preprocessing

그림 2. 데이터 전처리

3.2 암호화폐 선물 거래 시스템 구현

본 연구는 Google Colab 환경에서 Python 3.10, TensorFlow 2.15, 그리고 Keras 2.15 를 사용하여 딥러닝 모델을 개발하였다. 하드웨어로는 Google Colab 의 무료 GPU 인스턴스를 활용하였다. 모델 아키텍처는 그림 3 에 나타난 바와 같이 두 개의 LSTM 레이어(각각 256 유닛과 128 유닛)와 두 개의 Dense 레이어(64 유닛과 1 유닛)로 구성되었으며, 각 LSTM 레이어에는 0.05 의 드롭아웃(Dropout)을 적용하였다. 모델은 Adam 옵티마이저(learning_rate=0.001)를 사용하여 컴파일되었으며, 손실 함수로는 평균 제곱 오차(MSE)를 적용하였다. EarlyStopping 콜백을 사용하여 검증 손실이 10 에포크 동안 개선되지 않을 경우 훈련을 중단하고 최적의 가중치를 복원하도록 설정하였다. 배치 크기는 32, 에포크 수는 100 으로 설정하였으며, 검증 데이터를 통해 학습 파라미터를 지속적으로 개선하였다. 이러한 설정을 통해 모델은 효율적이고 안정적으로 훈련되었으며, 검증 세트에서 우수한 성능을 보였다.

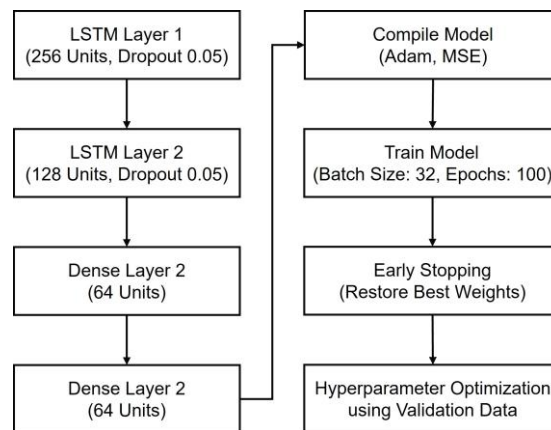


Figure 3. Deep learning architecture flow chart

그림 3. 딥러닝 아키텍처 흐름도

3.3 시스템 결과 계산

암호화폐 가격 예측 모델의 실질적인 성능을 평가하기 위해 기존 종가 기반 예측과 고가·저가 데이터 기반 예측 각각의 피어슨 상관관계수(Pearson Correlation Coefficient)와 거래 승률, 총 수익률을 측정하였다. 피어슨 상관관계수는 선형 상관 관계를 계량화한 수치로서, 1 부터 -1 사이의 값을 가지며, 1 에 가까울수록 양의 선형 상관 관계가 있음을 뜻하며, 0 은 선형 상관 관계가 없음, -1 은 음의 선형 상관 관계가 있음을 뜻한다. 실제 암호화폐의 가격과 예측한 결과값 사이에 선형 상관 관계를 알려준다. 훈련된 모델을 바탕으로 데이터를 원래 스케일로 되돌린 후, 예측된 가격을 사용하여 실제 거래를 실행함으로써 모델의 수익성을 평가하였다. 구체적으로, 예측된 가격이 전일 종가보다 높을 경우 매수 포지션을, 낮을 경우 매도 포지션을 취하는 방식으로 거래가 이루어졌다.

3.3.1 롱 포지션 수익률 계산

매수 포지션의 경우, 예측된 가격이 당일 실제 최고가보다 낮으면 해당 가격에서 포지션을 청산하여 수익을 확보하게 된다. 이때 수익은 아래 그림 4 의 수식 (1)에 따라 계산된다.

반면, 실제 최고가가 예측 가격보다 낮지만 전일 종가보다 높을 경우, 전일 종가와 실제 종가 간의 차이를 기준으로 수익이 계산된다. 만약 당일 종가가 전일 종가보다 낮을 경우 손실이 발생하며, 이는 아래 그림 4 의 수식 (2)를 통해 계산된다.

$$\text{Revenue}_{\text{long}} = \text{Revenue} \times \left(1 + \frac{|\text{pred}_i - \text{close}_{i-1}|}{\text{close}_{i-1}}\right) \quad (1)$$

$$\text{Revenue}_{\text{long}} = \text{Revenue} \times \left(1 - \frac{|\text{close}_i - \text{close}_{i-1}|}{\text{close}_{i-1}}\right) \quad (2)$$

Figure 4. Long Position Return Calculation Formula

그림 4. 롱 포지션 수익률 계산 공식

3.3.2 숏 포지션 수익률 계산

숏 포지션의 경우, 예측된 가격이 당일 실제 최저가보다 높으면 해당 가격에서 포지션을 청산하여 수익을 확보한다. 이때 수익은 그림 5의 수식 (1)에 따라 계산된다.

반면, 최저가가 예측 가격보다 높았지만 당일 종가가 전일 종가보다 낮을 경우 이익이 발생하며, 이 역시 수익 계산에 반영된다. 반면, 당일 종가가 전일 종가보다 높을 경우 손실이 발생하며, 이는 그림 5의 수식 (2)에 따라 계산된다.

$$\text{Revenue}_{\text{short}} = \text{Revenue} \times \left(1 + \frac{|\text{pred}_i - \text{close}_{i-1}|}{\text{close}_{i-1}}\right) \quad (1)$$

$$\text{Revenue}_{\text{short}} = \text{Revenue} \times \left(1 - \frac{|\text{close}_i - \text{close}_{i-1}|}{\text{close}_{i-1}}\right) \quad (2)$$

Figure 5. Short Position Return Calculation Formula

그림 5. 숏 포지션 수익률 계산 공식

모든 포지션은 당일의 예측값에 도달하여 미리 종료되지 않는 한, 손익 여부와 관계없이 당일 종가로 청산되는 손실 정지(stop-loss) 전략을 사용하였다. 이러한 전략을 통해 매일 새로운 포지션을 설정할 수 있으며, 이는 일일 변동성을 고려하여 시장 상황에 유연하게 대응할 수 있도록 한다.

IV. 연구 결과 및 고찰

본 연구에서는 암호화폐 선물거래 시스템 개발을 위해 종가 데이터와 고가·저가 데이터를 활용한 두 가지 모델의 예측 성능과 수익률을 비교 분석하였다. 이를 통해 각각의 데이터 유형이 암호화폐 거래에 미치는 영향을 확인하였다.

예측 성능의 경우 종가 데이터를 기반으로 한 모델이 고가·저가 데이터를 기반으로 한 모델보다 높은 성능을 보였다. 표 1에 나타난 바와 같이, ETH의 경우 종가 데이터 기반 모델의 Pearson 상관계수는 0.973, 승률은 80.1%로 나타났다. 반면, 고가·저가 데이터 기반 모델은 상관계수가 0.946, 승률은 77.9%로 상대적으로 낮았다. XRP와 DOGE 또한 유사한 경향을 보이며, 종가 데이터 기반 모델이 더 높은 상관성과 승률을 기록하였다. 이는 고가·저가 데이터 기반 모델이 더 높은 데이터 복잡성을 갖는 반면, 예측 정확도는 다소 낮아졌음을 시사한다.

Table 1. Comparison of Prediction Performance by Altcoin Data Type

표 1. 알트코인 데이터 유형별 예측 성능 비교

Altcoin	Prediction Data	Pearson Correlation Coefficient	Win Rate
ETH	Basic Data	0.973	80.1%
	Improved Data	0.946	77.9%
XRP	Basic Data	0.962	72.2%
	Improved Data	0.914	69.5%
DOGE	Basic Data	0.969	75.1%
	Improved Data	0.930	73.6%

수익률 분석에서는 고가·저가 데이터 기반 모델이 종가 데이터 기반 모델보다 더 높은 성과를 기록하였다. 표 2에 따르면, DOGE는 고가·저가 데이터 모델에서 45.96%의 수익률 증가를 보였으며, XRP와 ETH는 각각 32.71%와 6.27%로 개선되었다. 특히, DOGE의 경우 종가 데이터 기반 모델에서는 -13.19%로 음의 수익률을 기록한 반면, 고가·저가 데이터 기반 모델에서는 32.77%의 양의 수익률을 달성하여 큰 차이를 보였다. 이는 고가·저가 데이터 기반 접근법이 선물거래에서 중요한 변동성 반영에 효과적임을 보여준다.

Table 2. Profitability Comparison by Altcoin Data Type

표 2. 알트코인 데이터 유형별 수익률 비교

Altcoin	Basic Data Performance	Improved Data Performance	Profitability Gain
ETH	30.78%	37.05%	6.27%
restriction	64.78%	97.49%	32.71%
XRP	-13.19%	32.77%	45.96%

그림 6의 그래프 분석 결과는 모델이 도지코인의 실제 데이터와 예측 데이터를 비교적 잘 반영했음을 나타낸다. 그림 6(a) 그래프는 종가 데이터를 기반으로 한 예측 결과를 보여주며, 실제 데이터와 예측 데이터 간 유사도가 높아 모델의 높은 예측 성능을 확인할 수 있었다. 반면, 그림 6(b) 그래프는 고가·저가 데이터를 기반으로 한 예측 결과로, 데이터의 변동성을 잘 반영하고 있으나 실제 데이터와의 일치도가 상대적으로 낮은 경향을 보였다. 이는 데이터 복잡성과 모델 성능 간의 상충 관계를 고려해야 함을 보여준다.




Figure 6. DOGE Price Prediction Results: (a) Closing Price Data, (b) High and Low Price Data

그림 6. 도지코인 가격 예측 결과: (a) 종가 데이터 기준, (b) 고가·저가 데이터 기준

본 연구를 통해 고가·저가 데이터를 활용한 모델은 암호화폐 선물거래에서의 특성을 보다 잘 반영하며, 변동성이 높은 시장에서 투자 전략의 수익성을 극대화할 가능성을 보여준다. 이러한 결과는 선물거래 시스템 설계 시 고가·저가 데이터가 실질적으로 중요한 역할을 할 수 있음을 암시하며, 향후 연구 방향에 중요한 시사점을 제공한다.

V. 결론

본 연구는 암호화폐 선물거래 시스템에서 데이터 유형이 예측 성능과 수익률에 미치는 영향을 분석하였다. 종가 데이터를 기반으로 한 모델은 높은 예측 정확도와 안정적인 성능을 보였으나, 고가·저가 데이터를 기반으로 한 모델은 변동성이 높은 시장 상황에서 더 높은 수익률을 기록하며 선물거래의 특성을 효과적으로 반영하였다.

고가·저가 데이터를 기반으로 한 모델은 예측 성능 측면에서는 종가 데이터 기반 모델에 비해 다소 낮은 결과를 보였으나, 수익률 측면에서는 더 나은 결과를 보였다. 특히, 상대적으로 변동성이 낮은 이더리움은 6.27%의 수익률 개선을 보인 반면, 상대적으로 변동성이 큰

도지코인은 45.96%의 수익률 개선을 이루었으며, 리플은 32.71%의 개선을 보였다.

결과적으로, 고가·저가 데이터를 활용한 모델은 암호화폐 선물거래에서 변동성을 반영한 효과적인 전략으로 작용할 수 있으며, 이는 특히 고변동성 자산에서 중요한 시사점을 제공한다. 다만, 예측 성능 저하와 모델 복잡성 증가라는 한계가 있으므로, 향후 연구에서는 TFT, FEDformer, PatchTST, TimesNet 등 다양한 최신 시계열 예측 알고리즘을 비교·분석해 각 모델의 특성과 시장 조건별 최적의 트레이딩 방식을 도출할 계획이다. 이를 위해 SHAP(Shapley Additive Explanations) 분석과 Attention 가중치 시각화 기법을 함께 활용해 각 입력 피처의 중요도를 정량화하고, 변동성 수준 및 시장 상황에 따른 기여도 변화를 체계적으로 평가할 것이다.

이러한 접근은 단순히 수익성 개선에 그치지 않고, 모델 해석력과 피처 중요도 분석을 바탕으로 거래 전략 설계 및 실전 적용 가능성을 높이는 방향으로 확장될 수 있다. 또한, 뉴스 감성 분석, 경제 지표, 소셜 미디어 지표 등 외부 요인을 추가로 통합한 다차원적 예측 모델 개발을 통해 보다 높은 예측 정확도와 수익성을 동시에 달성하는 암호화폐 선물거래 시스템 구축으로 발전할 수 있을 것으로 기대된다.

VI. 참고문헌

- [1] D. Kochergin, "Crypto-assets: Economic Nature, Classification and Regulation of Turnover," *Int. Organ. Res. J.*, Vol. 17, No. 3, pp. 75–113, 2022.
- [2] H. Elendner, S. Trimborn, B. Ong, and T. M. Lee, "The Cross-section of Crypto-currencies as Financial Assets: An Overview," SFB 649 Discussion Paper, 2016.
- [3] P. K. Donepudi, "Automation and Machine Learning in Transforming the Financial Industry," *Asian Business Review*, Vol. 9, No. 3, pp. 129–138, 2019.
- [4] A. Ganapathy, M. Redwanuzzaman, M. M. Rahaman, and W. Khan, "Artificial Intelligence Driven Crypto Currencies," *Global Disclosure of Economics and Business*, Vol. 9, No. 2, pp. 107–118, 2020.
- [5] G. Lucarelli and M. Borrotti, "A Deep Reinforcement Learning Approach for Automated Cryptocurrency Trading," in *Proc. of the 15th IFIP WG 12.5 Int'l Conf., AIAI 2019, Hersonissos, Crete, Greece, 2019*, pp. 247–258.
- [6] R. C. Staudemeyer and E. R. Morris, "Understanding LSTM—A Tutorial into Long Short-term Memory Recurrent Neural Networks," *arXiv Preprint*, arXiv:1909.09586, 2019.
- [7] J. P. Fleischer, G. von Laszewski, C. Theran, and Y. J. Parra Bautista, "Time Series Analysis of Cryptocurrency Prices Using Long Short-term Memory," *Algorithms*, Vol. 15, No. 7, p. 230, 2022.
- [8] P. Bilokon and Y. Qiu, "Transformers versus LSTMs for electronic trading," *arXiv Preprint*, arXiv:2309.11400, 2023.
- [9] P. L. Seabe, C. R. B. Moutsinga, and E. Pindza, "Forecasting Cryptocurrency Prices Using LSTM, GRU, and Bi-directional LSTM: A Deep Learning Approach," *Fractal and Fractional*, Vol. 7, No. 2, p. 203, 2023.
- [10] M. J. Hamayel and A. Y. Owda, "A Novel Cryptocurrency Price Prediction Model Using GRU, LSTM and Bi-LSTM Machine Learning Algorithms," *AI*, Vol. 2, No. 4, pp. 477–496, 2021.
- [11] M. A. L. Khaniki and M. Manthouri, "Enhancing Price Prediction in Cryptocurrency Using Transformer Neural Network and Technical Indicators," *arXiv Preprint*, arXiv:2403.03606, 2024.
- [12] X. Huang, W. Zhang, X. Tang, M. Zhang, J. Surbiryala, V. Iosifidis, Z. Liu, and J. Zhang, "LSTM Based Sentiment Analysis for Cryptocurrency Prediction," in *Proc. of the 26th Int'l Conf., DASFAA 2021, Taipei, Taiwan, 2021*, pp. 617–621.
- [13] E. Loginova, W. K. Tsang, G. van Heijningen, L.-P. Kerkhove, and D. F. Benoit, "Forecasting Directional Bitcoin Price Returns Using Aspect-based Sentiment Analysis on Online Text Data," *Machine Learning*, Vol. 113, No. 7, pp. 4761–4784, 2024.
- [14] G. Serafini, P. Yi, Q. Zhang, M. Brambilla, J. Wang, Y. Hu, and B. Li, "Sentiment-driven Price Prediction of the Bitcoin Based on Statistical and Deep Learning Approaches," in *Proc. of the 2020 Int'l Joint Conf. on Neural Networks (IJCNN)*, 2020, pp. 1–8.
- [15] S. Colianni, S. Rosales, and M. Signorotti, "Algorithmic Trading of Cryptocurrency Based on Twitter Sentiment Analysis," *CS229 Project*, Vol. 1, No. 5, pp. 1–4, 2015.

- [16] F. Valencia, A. Gómez-Espinosa, and B. Valdés-Aguirre, "Price Movement Prediction of Cryptocurrencies Using Sentiment Analysis and Machine Learning," *Entropy*, Vol. 21, No. 6, p. 589, 2019.
- [17] A.-D. Vo, Q.-P. Nguyen, and C.-Y. Ock, "Sentiment Analysis of News for Effective Cryptocurrency Price Prediction," *Int. J. Knowl. Eng.*, Vol. 5, No. 2, pp. 47–52, 2019.
- [18] A. K. Kulbhaskar and S. Subramaniam, "Breaking News Headlines: Impact on Trading Activity in the Cryptocurrency Market," *Econ. Model.*, Vol. 126, p. 106397, 2023.
- [19] S. A. Farimani, M. V. Jahan, A. M. Fard, and S. R. K. Tabbakh, "Investigating the Informativeness of Technical Indicators and News Sentiment in Financial Market Price Prediction," *Knowl.-Based Syst.*, Vol. 247, p. 108742, 2022.
- [20] S. Corbet, B. Lucey, M. Peat, and S. Vigne, "Bitcoin Futures—What Use Are They?," *Econ. Lett.*, Vol. 172, pp. 23–27, 2018.
- [21] C. Zhang, H. Ma, G. B. Arkorful, and Z. Peng, "The Impacts of Futures Trading on Volatility and Volatility Asymmetry of Bitcoin Returns," *Int. Rev. Financ. Anal.*, Vol. 86, p. 102497, 2023.

저자소개



최민석(Minseok Choi)

2020 년 3 월~현재 강남대학교 소프트웨어응용학부 학부생

관심분야 : 인공지능, 암호화폐, 자동매매



주해중(Haejong Joo)

2008 년~2009 년 경희사이버대학교 컴퓨터정보통신학과 객원교수

2010 년~2023 년 동국대학교 공과대학 컴퓨터공학과 부교수

2023 년~현재 강남대학교 공과대학 인공지능융합공학부 교수

관심분야 : 데이터마이닝, AI 융합



최웅(Woong Choi)

2005 년~2010 년: Ritsumeikan University

2010 년~2022 년: National Institute of Technology, Gunma College

2022 년~현 재: 강남대학교 컴퓨터공학부 부교수

관심분야 : 가상현실, 휴먼 컴퓨터 인터랙션 등